

ECDSA-Fail 可逆点加挑战： 背景、nonce 搜索、其瓶颈， 以及 ecdsafail-agent 如何攻克它们

Brevis — ben@brevis.network（与 Claude 协作）

2026-06-17（前沿 1caf521, $q = 1168$ ）

摘要

本报告系统性地记录了在本仓库中开展的 `ecdsa.fail` 优化挑战。内容涵盖：（1）挑战背景；（2）为什么它很难；（3）为什么每一次电路改进都会强制触发一次全新的 *nonce* 搜索；（4）*nonce* 搜索流水线及其瓶颈；（5）`ecdsafail-agent` 中的工具链如何攻克这些瓶颈——含保证 GPU 工具与官方电路严格对齐的对齐门；（6）从两个同行仓库（`ecdsafail_skills` 与 `ecdsafail_gpu_toolkit`）借鉴了哪些思路、各自解决了什么问题。所有数字均在当前本地前沿 1caf521 ($q = 1168$)、于 8×RTX-5090 主机 `zan3` 上实测得到。

目录

1	挑战背景	2
2	这个挑战的难点	3
3	为什么需要一次 <i>nonce</i> 搜索（“hunt”）	5
3.1	三个校验通道：cls / pha / anc	6
4	Nonce 搜索流水线与其瓶颈	7
4.1	流水线	7
4.2	流水线各组件（zan3 上、仓库内的文件）	7
4.3	经济学	7
4.4	瓶颈	9
5	为什么相位极难清零（优化的对偶代价）	9
6	ecdsafail-agent 如何攻克这些瓶颈	10
6.1	把 validator 搬上 GPU（直接打掉瓶颈）	10

6.2	解析预过滤：不跑 op-loop 就筛掉绝大多数 nonce	11
6.3	两阶段 GPU 流水线 (Lever B)	12
6.4	工具对齐门：信任任何 GPU verdict 的前提	12
6.5	对改比较器的候选做 filter 校准	13
6.6	投 fleet 前的筛选与判定 (约 10 分钟预检)	13
6.7	标定的运行时模型	14
6.8	Worked example: 候选 cb45 (COMPARE_BITS 46→45)	14
6.9	把整条搜索加速的杠杆 (按收益排序)	14
7	从两个同行仓库借鉴的思路	15
7.1	来自 ecdsafail_skills	15
7.2	来自 ecdsafail_gpu_toolkit	16
7.3	本仓库相对 ecdsafail_gpu_toolkit 的关键领先	16
8	新工作流为何更好 (之前 → 现在)	17
9	当前状态与开放项	17

1 挑战背景

挑战目标是一个可逆 (量子) 电路, 它把一个量子态的椭圆曲线点与一个经典椭圆曲线点在 `secp256k1` 上相加。该电路是 Shor 式攻击 ECDSA 的内层原语; 竞赛要求参赛者最小化它的资源开销。电路在内部计算的是仿射点加 $R = P + Q$ (P 为目标寄存器里的量子点, Q 为偏移比特里的经典点), 其代数步骤见图 1; 而把代码跑成一个可计分提交的官方评测流程 (含认证器 validator) 见图 2。

评分。 目标是如下乘积:

$$\text{score} = (\text{平均执行的 Toffoli 数}) \times (\text{峰值 qubit 数}), \quad \text{越小越好。}$$

- **峰值 qubit** 是整条电路在任意时刻同时存活的 qubit 数的最大值——一个 随时间取的 *max*, 由那一个最宽的瞬间 (即绑定者 *binder*) 决定。
- **平均执行 Toffoli** 是在 9024 个测试 shot 上、真正触发的 Toffoli (CCX) 门数的均值 (受数据/测量条件控制的门, 按其触发比例计入, 而非按静态存在与否)。

校验。 一次提交只有在所有 9024 个测试输入上**完美可逆**时才会被计分: 0 经典失配 / 0 phase-garbage / 0 ancilla-garbage (记作 “0/0/0”)。测试输入由对电路 op-stream 做 **SHAKE256** 挤压 (squeeze) 确定性地导出 (一个 Fiat-Shamir 构造): 每个 shot s 抽出两个标量 k_1, k_2 , 形成 $t = k_1 G$ 和 $o = k_2 G$, 期望输出是仿射和 $e = t \oplus o$ 。




图 1: 电路计算的代数步骤 (Roetteler 式双-Kaliski 点加, 见 `src/point_add/mod.rs` 的算法注释)。注意两处加粗块: ❷ 模逆是开销主战场; ❻ 反计算把所有中间量擦回 0——这正是“可逆”的要求, 也是后文 `anc` 通道所校验的 (见 §3.1)。

当前状态。 公开最优为 **1,672,963,776** (commit 1caf521, $q = 1168$)。qubit 前沿在活跃期内一路下降: 1211 $\rightarrow$ 1203 $\rightarrow$ 1193 $\rightarrow$ 1192 $\rightarrow$ 1185 $\rightarrow$ 1170 $\rightarrow$ 1168; 1caf521 处的电路 $\approx$ 10.26M 个 op。官方评测工具是两个二进制 (流程见图 2): `build_circuit` (从参赛者的 `build()` 生成 `ops.bin`), 以及 `eval_circuit` (受信任的认证器: 重新读取 `ops.bin`, 模拟全部 9024 个 shot, 强制 0/0/0, 写出 `score.json`)。

2 这个挑战的难点

两个互相耦合因子的乘积。 因为 score 是 Toffoli $\times$ qubits, 这两个因子互相博弈、必须协同优化。释放一个 qubit 通常要付出 Toffoli 代价 (uncompute/recompute), 而削减 Toffoli 有时又要付出一个 qubit (例如一个 vent 多占一个 ancilla)。决策准则是一个 兑换率: 在当前前沿, 一个峰值 qubit 价值 $\approx$ 1.1–1.4M 分 (经验上 $\approx$ 十几次 Toffoli 打磨型提交), 所以一个 qubit 几乎总是胜过一个 Toffoli 小缺口——但前提是你能值精确地 (*value-exactly*) 把它释放掉。

峰值是一个移动的、多相位的平台。 在成熟电路上, 峰值不是一座孤立的高塔, 而是一个平台: 若干互相独立的相位并列在同一高度。在 1caf521, 绑定者是 `dialog_gcd_apply_chunk_sub_ripple`; 其附近的峰值被 `apply fold` 与第 84 轮的 Solinas square 双重钉住 (*dual-pinned*)。要把这个数压下去, 就必须对每一个共同绑定者做协调一致的修改——只削掉一个, 其它的仍卡在峰值。每次修改后绑定者都会迁移, 所以这是一场打地鼠。




图 2: 官方评测 (代码) 流程与信任边界。参赛者代码只在不可信的 `build_circuit` 里运行; 受信任的 `eval_circuit` 在另一个进程里从磁盘重读 `ops.bin`、且从不 `import` 参赛者代码——因此参赛者代码无法影响计分。校验器 (validator) 就是 `eval_circuit` 的 ④: 它把测试岛由 `op-stream` 经 SHAKE256 确定性导出, 故任何对 `op-stream` 的改动都会重洗测试岛 (这正是后文需要重新 hunt nonce 的根源, 见 §3)。

两种正确性机制。 宽度削减是二值失败的: 要么值精确 (在每个输入上都对), 要么几乎破坏所有输入——没有渐进的“接近正确”阶梯, 所以必须先证明其正确、再 0/0/0 校验, 然后才能搜索。而 Toffoli 截断是分级失败的: 它只在那些在可达验证支撑集上可证为零的比特上才精确, 并在别处引入一小撮、可刻画的硬输入 (*hard inputs*)。

前沿很深, 许多轴已被耗尽。 在调校过的基线上, 便宜的旋钮已经走平 (开销变为分配受限, 迫使做结构性代码改动), 而几个看似诱人的结构性想法在这里已被证明是死路:

- **jumpdivsteps** (Bernstein–Yang 矩阵批处理): 一次 $\text{jump-}T$ 矩阵-apply 需要四次 量子 $\text{small} \times 256$ 乘法, 约为它所替代的便宜 33-bit 经典常量 ripple 的 $\approx 2.6\times$, 且会加宽 GCD 柱。NO-GO。
- **批量对偶求逆** (主多项式 $M = d_1^2 d_2$): $+1.26\text{--}1.3\text{M}$ CCX, 因为融合路径里没有可摊销的独

立乘法。

- **通用 ZX/T-par peephole**: 在这条手工调校过的电路上实测 0 次抵消。
- **仅靠旋钮压子峰**: 堆叠进位截断会撞上一个不可约的 `cls=2` 结构地板；真正的进展需要一次电路代码层面的改动。

3 为什么需要一次 nonce 搜索 (“hunt”)

测试输入是 op-stream 的确定性函数 (SHAKE256 Fiat-Shamir)。所以任何对 op-stream 的改动都会把全部 9024 个 shot 重新洗牌。一个在旧 shot 的可达支撑集上精确的截断，几乎绝不会在新 shot 上仍精确——它会获得硬输入，校验随即失败。

逃生口是一个免费的 nonce: 电路在尾部追加一个固定的 96-op 恒等尾巴 (48 对 $x;x$, 由 `DIALOG_TAIL_NONCE` 控制, `NONCE_BITS=48`; 见 `src/point_add/mod.rs` 约 L1773)。这条尾巴对量子态是恒等的——它不改变所计算的函数, 也不改变门计数——但它扰动了 op-stream 的字节, 从而扰动 SHAKE256 哈希, 从而扰动那 9024 个 shot。于是:

“尝试一个 nonce N ” = 为 $\text{hash}(\text{ops} \parallel N)$ 重新导出 Fiat-Shamir 测试岛 (*island*), 并检查 (未改变的) 电路是否恰好在那个特定岛上 0/0/0。

因此, 一次降分改动由两部分组成: (a) 降低 Toffoli $\times$ qubits 的 op-stream 编辑; (b) 一个干净 nonce, 其重洗后的岛恰好躲开该编辑引入的每一个硬输入。第 (b) 部分就是 nonce 搜索。

什么是“硬输入” (hard input)。降分的手段 (Toffoli 截断、把比较器变窄如 `COMPARE_BITS` 46 $\rightarrow$ 45、进位截断等) 本质上都是在赌某个高位 / 进位 / 余项是 0: 完整电路对所有输入都精确, 而截断电路只在“被丢掉的那几位在该输入上确实为 0”时才精确。对绝大多数输入这个赌注成立、结果照样对; 但对极少数输入那几位并非 0——截断丢掉了本该保留的信息, 结果出错。这些让赌注落空的输入, 就是硬输入: 它们是用“在一小撮罕见输入上算错”换“更少的门 / 更少的 qubit”的代价。具体到本电路, 每个 shot 的 t, o 以及模逆量 $dx = P_x - Q_x$ 、 $c = Q_x - R_x$ 的比特模式决定了二进制-GCD 行走的步数 / 进位 / 比较结果; 某个 shot 若踩中截断所赌的“应为 0 却不为 0”情形, 就成为一个硬输入, 并按踩中的环节点亮对应通道 (GCD/算术 $\Rightarrow$ `cls`; 测量-uncompute 留相位 $\Rightarrow$ `pha`; scratch 没擦净 $\Rightarrow$ `anc`, 三通道含义见 §3.1)。

硬输入密度与“悬崖”。 一次给定的截断, 在所有可能输入里有一个固定的硬输入密度。设每个岛 (9024 个输入) 期望踩中的硬输入数为 λ , 则按 Poisson 近似一个 nonce 干净的概率

$$P(\text{clean}) \approx e^{-\lambda},$$

所以 λ 稍涨一点, 干净 nonce 就指数级变稀有——这就是“截断悬崖” (WIDTH_SLOPE 方向上每加一档密度 $\sim 25\times$)。截断越激进 $\Rightarrow$ 硬输入越多 $\Rightarrow \lambda$ 越大 $\Rightarrow$ hunt 时间爆炸。这正是要挑亚悬崖 / 值精确候选的原因: 新增硬输入尽量少、 λ 才低、hunt 才短 (搜索就是去找一个 9024 输入里一个硬输入都没踩中的岛)。

3.1 三个校验通道：cls / pha / anc

“0/0/0”里的三个数，正是官方认证器 `eval_circuit` 在每个 shot 上独立统计的三种失败计数（见 `src/bin/eval_circuit.rs` 约 L275–L331）。理解它们，要先记住：这是一条**可逆**电路，理想情况下它必须是计算基态上的一个纯置换——把输入态 $|t, o, \text{scratch}=0\rangle$ 干净地映成 $|e, \dots, \text{scratch}=0\rangle$ ，不带任何残留。三个通道恰好检查这个“纯置换”的三个必要条件：

cls (classical mismatch, 经典失配)

跑完电路后，读出两个输出寄存器 (g_x, g_y) 与期望的 $(e_x, e_y) = t \oplus o$ 比较；只要有一个比特不等就记一次失配。直白说：**算出来的点加结果错了**。在本电路里这通常源自二进制-GCD 模逆 (“dialog-GCD” 行走) 或下游算术在某个“硬输入”上被截断截过了头。逐 *shot* 计数。

pha (phase-garbage, 相位垃圾)

认证器跟踪一个逐 shot 的相位寄存器 `sim.phase`；批次跑完后它必须为 0，否则记一次相位垃圾。含义：即便输出比特全对，电路也可能给基态附加了一个相对相位 $|\psi\rangle \rightarrow e^{i\theta}|\psi\rangle$ ——那它就不是我们要的那个置换酉算子了。在 Shor 攻击里点加要作用在叠加态上，残留相位会破坏干涉，所以必须为 0。相位主要由**基于测量的 uncompute** (Hmr/R 门) 的随机测量结果决定。逐 *batch* 计数。

anc (ancilla-garbage, 辅助比特垃圾)

把输出寄存器清零后，所有其余非寄存器 *qubit*（即计算过程中临时借用的 *scratch* / 辅助比特）必须在每个存活 shot 上都回到 $|0\rangle$ ；只要有一个非零就记一次。含义：**借来的草稿纸没擦干净**。一次正确的可逆计算必须把所有中间量反计算 (*uncompute*) 回 0，否则这些脏比特仍与输出纠缠，电路就不是一个干净置换（也无法把这些 *qubit* 安全回收复用）。逐 *batch* 计数。

“三个都要等于 0 才通过”是什么意思。 一次提交只有当这三个计数在全部 9024 个 shot 上同时为零（即 0/0/0）时才被判为合法、才会计分。nonce 搜索做的事就是：电路本身固定不动，只换 nonce（从而换一组 9024 个测试输入），去找一个让这三个计数恰好全归零的岛。一个优化截断会在某些输入上“踩雷”——这些就是**硬输入**：踩中 GCD/算术的雷 $\Rightarrow \text{cls} > 0$ ；测量 *uncompute* 留下相位 $\Rightarrow \text{pha} > 0$ ；*scratch* 没擦净 $\Rightarrow \text{anc} > 0$ 。搜索的目标，就是一个其岛恰好绕开所有三种雷的 nonce。

为什么 hunt 里主要盯 cls 与 pha (“dual-clean”)。 *anc* 在本电路里几乎从不独立失败：辅助比特的反计算与点加结果由同一段算术驱动，所以 *scratch* 没擦净时输出几乎总是同时也错 (*cls* 一起亮)——*anc* 基本是 *cls* 的“伴随”而非独立的绑定通道。真正互相独立、必须分别归零的是**经典与相位**两条轴：经典看算术对不对，相位看测量-*uncompute* 的随机结果干不干净，二者由不同的机制决定（后文 §5.4 的 leak 诊断会量化这种独立性）。因此 GPU hunt 把对每个 nonce 同时干净于这两条轴的称为**双重干净 (dual-clean)**，并把唯一的 dual-clean 赢家交给 CPU `eval_circuit` 复核完整的 0/0/0（含 *anc*）后才提交。

4 Nonce 搜索流水线与其瓶颈

4.1 流水线

对每个候选 nonce N ，流程如图 3 所示，文字描述如下：

1. 导出岛：SHAKE256(op-stream $\parallel N$)；
2. 对每个 shot $s \in [0, 9024)$ ：挤压出 k_1, k_2 ，计算 $t = k_1 G$ 、 $o = k_2 G$ （EC 标量乘），跳过退化情形后压实，形成期望 $e = t \oplus o$ ；
3. 校验电路在该岛上的表现：经典轴（GCD 求逆是否正确？）与相位轴（全局相位是否为 0？）；
4. 一个双重干净的 nonce $\rightarrow$ 交给 CPU eval_circuit 重新认证一次 0/0/0 $\rightarrow$ 若 score < 前沿则 bake 并提交。

4.2 流水线各组件（zan3 上、仓库内的文件）

表 1 列出各组件、其角色，以及它是否需要跑那条 10.3M-op 的 op-loop。

组件	角色	跑 op-loop?	速度量级
build() / src/point_add	生成 10.3M-op 流 (ops.bin)	—	—
eval_circuit (官方)	读 ops.bin, 全仿真, 认证器	是 (CPU)	仅最终赢家跑 1 次
fast-screen (CPU agent)	进程内 build + 全仿真, 1 nonce/进程	是 (CPU)	≈ 0.08 /核
gcd.cu / gpu-nonce	解析 经典 预过滤 (GCD replay)	否 (快)	$\approx 8.6k$ – $23.5k$
verify_dual / hunt_phase.cu	融合 GPU 经典 + 相位 评测 (精确)	是 (GPU)	≈ 169 (8 卡 1,355)
circuit_prep	为 GPU kernel 导出重映射电路	—	—
phase_ref	CPU 金标准 (FS + op-loop), 与 eval_circuit 逐比特一致	是 (CPU)	—

表 1: 流水线组件。关键机制：**nonce 在 op-stream 里**（即 X;X 尾巴），而 eval_circuit 读的是预建的 ops.bin，所以 CPU 校验某个 nonce 需要一份把该 nonce baked 进去的 ops.bin；GPU kernel 则**在设备上把 nonce 吸收进 FS 哈希**（无需 rebuild），这正是 GPU 能流式扫过数百万 nonce 的原因。

4.3 经济学

经典轴原则上可由一次便宜的解析 *GCD replay* 判定（无需跑电路）。**相位轴**则只能通过跑满 $\approx 10.3M$ -op 的整条电路来判定（相位依赖于每一个门，外加测量-uncompute 的 RNG）。所以理想的流水线应当用便宜的解析 GCD 预过滤拒掉绝大多数 nonce，只对 GCD-clean 幸存者支付昂贵的 op-loop。在 1caf521 实测：gcd.cu 每 nonce 通过率 $\approx 0.09\%$ （约 890/M-nonce，即拒掉 $\approx 99.9\%$ ），而它放过的 GCD-clean 候选里，只有 $\approx 20\%$ 在精确 op-loop 下真正经典干净——其余 $\approx 80\%$ 是




图 3: 两阶段 nonce 搜索流水线。便宜的解析经典预过滤 (Stage-1) 拒掉绝大多数 nonce; 昂贵的精确 op-loop (Stage-2) 只在 Stage-1 幸存者上运行; 唯一的赢家在提交前由官方 CPU `eval_circuit` 复核。(S2 节点标的 $\approx 169/1,355$ 是验证器在原始流上的速率, 不是两阶段里 Stage-2 的吞吐——管线扫原始 nonce 的速率是 Stage-1 的、约 $100\times$ 于它; 见 §6.3 “三个别混淆的速率”。)

apply 阶段截断造成的 false-clean (`gcd.cu` 只建模 GCD 求逆段, 不管 apply, 见后文 “一个关于预过滤的微妙翻转” 段)。

4.4 瓶颈

精确校验器对每个 nonce 都跑满整条 op-loop。实测速率（表 2）表明 op-loop 就是瓶颈：它在每个 nonce 上都支付 10.3M-op 的代价，连那 $\approx 99.9\%$ GCD-hard 的也照付。

评测器	硬件	速率 (nonce/s)
CPU fast-screen (经典 + 相位全跑)	1 核	≈ 0.08
CPU fast-screen	整个 fleet (≈ 470 核)	≈ 40
GPU gcd.cu 经典预过滤	1 张 RTX-5090	$\approx 8.6\text{k}-23.5\text{k}$
GPU verify_dual (经典 + 相位 op-loop)	1 张 RTX-5090	$\approx 100-169$
GPU verify_dual	8 张 RTX-5090	$\approx 1,355$

表 2: 各阶段实测吞吐。op-loop 校验器（底部）比解析经典预过滤（中部）慢约 $\sim 100\times$ 。

根本性的墙。 一个全新赢家需要约 $1/P(\text{dual-clean})$ 个 nonce，而 $P(\text{dual-clean})$ 很小（在 84d5b0e 上 $\approx 3 \times 10^{-8}$ ，即一个新赢家要扫 $\sim 10^7-10^8$ 个 nonce）。吞吐加速是线性的——它按比例缩短墙钟时间，却无法让一个稀有岛候选变得“立刻”。因此战略性的杠杆是：(a) 让便宜的预过滤拒掉更多；(b) 挑选亚悬崖 (*sub-cliff*) 候选，使其引入的硬输入数尽量小、从而让 P 保持较高。

5 为什么相位极难清零（优化的对偶代价）

相位通道是 nonce 搜索的绑定墙 ($P(\text{pha}=0 \mid \text{cls}=0) \approx e^{-10}$)。它为何如此难清零，有一个干净的结构性解释——**相位之难，正是 Toffoli 优化的对偶代价。**

1. 纯经典-可逆电路本来没有相位。 只用 CX/CCX/X/Swap 的电路是一个置换，它不产生相位。相位只来自 Z-基门 (CZ/CCZ/Z/Neg) 与测量 (Hmr/R)。可这条电路计算的是经典 point-add（一个置换），按理不该有相位门——然而它含约 **84 万个 CZ**（本地实测：840,611 个相干相位门）。

2. 这些 CZ 是优化硬塞进来的。 夺取前沿全靠把昂贵的相干 **uncompute** (Toffoli) 换成便宜的相位记账 (CZ + 测量)：

- **measured uncompute**：测量掉一个 ancilla（省 CCX），但测量留下相位 kickback，需用 CZ 修正抵消；
- **phase-conditioned comparator replay** (*_CONDITIONAL_REPLAY)：不跑相干比较器，而是测出比较标志并用 CZ 树 *replay* 谓词以抵消相位（执行 Toffoli $\rightarrow 0$ ）；
- **truncated / top-clean 算术**：截断加法器、边界清理用相位修正代替进位 uncompute。

实测的相位门分布印证了这一点（按 phase 区域桶分 840,611 个 CZ，见表 3）：它们集中在 **apply chunk** ($\approx 46\%$) 与 **round84 square** ($\approx 17\%$) ——正是重度以相位技巧省 Toffoli 的相位。

相干相位门所在区域	占比	可便宜解析 replay?
apply chunk (boundary_clear + clear + ripple)	≈ 46%	否 (需完整 apply 态)
round84 square (forward + inverse)	≈ 17%	否 (需完整乘法态)
apply double_y / halve_y	≈ 7%	否
special folds (模约简)	≈ 14%	部分
GCD 侧 (tobitvector + branch_bits)	≈ 22%	是 (GCD-step 量)

表 3: 相干相位门 (CZ/CCZ/Z/Neg, 共 840,611) 按电路 phase 区域的分布。约 63% 落在 apply 与 square——其控制依赖完整量子态演化, 无法像 GCD 那样被便宜地单独 replay。

3. 这些相位修正只在“可达 support”上精确。 每棵相位修正 CZ 树, 都是按“输入必落在合法 secp256k1 point-add 的可达取值语言内”设计为恰好抵消的。但 9024 个测试 shot 由 SHAKE 随机导出, 会有输入飘出该 support 一点点; 在那些输入上相位抵消不完全 → **残留全局相位**。约 10 个 shot 命中某个站点的 off-support 相位条件。要 pha=0 即全部 9024 个输入都避开所有站点的相位破绽 → $P \approx e^{-(\text{均值})} \approx e^{-10}$, 故稀有。

4. 为何与经典独立 (leak ≈ 1)。 相位只影响全局相位, 不影响所计算的 值。一个 off-support 输入可以**值算对** (classical clean), 但那棵假设了它 bit 模式的 CZ 修正树仍留下残相位。值对、相位错——二者在不同的 off-support 条件上失败, 故独立。

5. 为何相位比经典更难清零。 经典硬输入主要来自**截断** (被丢的位非零) ——结构化、相关 (双峰: 一个 island 要么整体避开、要么不), 且有便宜的 GCD-replay 模型可富集, 故 $P(\text{cls}=0) \approx 18\%$ (不难)。相位硬输入则来自**散布全电路 840k 个 CZ 站点的抵消失败**——各站点独立贡献一小撮 → 更像 Poisson (~10), 无双峰逃逸; 且散在 apply/square, **无便宜解析模型**可富集 (实测确认: 关闭全部 measured-uncompute 后相位均值仍 ≈ 10.6 不变 ⇒ 相位源是相干 CZ, 而非测量; 而 CZ 的控制需完整态, 无法便宜 replay)。所以相位既本质更深、又无法预过滤。

6. 最深的反讽: 越优化, 相位越难。 相位之难, 正是 Toffoli 优化的代价。前沿电路被优化到极致——到处把 Toffoli 换成相位修正——所以它的相位对应地极难保持干净。越想 *beat frontier* (更多优化、更多截断/replay), 相位墙越高, 而非越低。这就是没有“躲相位”捷径的根本原因: 相位之难是高度优化电路的内在属性, 而不是某个可绕开的工具缺陷。

6 ecdsafail-agent 如何攻克这些瓶颈

6.1 把 validator 搬上 GPU (直接打掉瓶颈)

§4 指出瓶颈就是那条精确 validator (op-loop)。历史上 validator 是 CPU fast-screen (即便整个 ≈ 470 核的 fleet 也只有 ≈ 40 nonce/s)。首要的攻克手段是**把整个 validator ——完整 10.3M-op 电路、经典与相位、全 9024 shot——整体搬到 GPU 上**, 即 verify_dual / hunt_phase.cu (在

设备端把 nonce 吸收进 FS 哈希, 无需 rebuild): ≈ 169 nonce/s/卡、8 卡 $\approx 1,355$ nonce/s, 约为整个 CPU fleet 的 **34**×。这是基础; 其上再用两阶段切分 (§6.3) 确保昂贵的 op-loop 只在便宜预过滤的幸存者上跑。(这一点也是本仓库相对竞品 `ecdsafail_gpu_toolkit` 的关键差异, 详见 §7。)

6.2 解析预过滤: 不跑 op-loop 就筛掉绝大多数 nonce

GPU validator 把 op-loop 加速了 34×, 但 op-loop 本身仍然昂贵——它要在 ≈ 1168 个 qubit 上把 10.3M 个 op 整体演化一遍。第二个攻克手段是**对绝大多数 nonce 干脆不跑 op-loop**: 注意经典判决 (GCD 模逆是否正确) 由一个**局部子计算**决定——二进制-GCD 在 (u, v) 上的递推——它可以纯经典地 replay (几个 256-bit 整数, **不需要任何量子态演化**)。

它具体怎么做。 `gcd.cu` (移植自 `dialog_gcd_classical_filter.rs`) 对每个 shot、每个 GCD 因子 f ($dx = P_x - Q_x$ 与 $c = Q_x - R_x$, 两个都查; 只查 dx 会把硬率低估约 2×) 做如下纯整数重放——它就是硬件那条二进制-GCD walk 的整数复刻, 逐步施加与电路完全相同的截断:

1. **初始化** $u = p$ (secp256k1 素数), $v = f$ 。
2. **重放** `ACTIVE_ITERATIONS` = 258 步, 每步:
 - 取该步的截断宽度 `active_width(step)` 与截断比较位 `compare_bits`; 用截断比较器算分支位 `trunc_gt = cmp_gt_truncated(u, v)`——**硬件就是按这个截断决定走的**, 所以这里也按它走 (截断-vs-全宽比较器即便不一致也不判 hard: 硬件跟随截断决定, 在可达 support 上仍走到正确逆元, 强行标记会误杀真干净 island);
 - $b_0 = \text{bit}_0(v)$, $b_0 \wedge b_1 = b_0 \wedge \text{trunc_gt}$; 若成立则在 cswap 宽度内条件交换 (u, v) ;
 - 若 b_0 : $v \leftarrow (v - u)$ 截断到 `body_carry_trunc_width` (带 odd- u lowbit fastpath 的 $\oplus 1$)——这一步就是电路里截断进位的体现;
 - 右移 v (GCD 的折半); 若 K2 再做一次条件右移 ($s_2 = \neg \text{bit}_0(v)$);
 - 记录该步决策 $(b_0, b_0 \wedge b_1, s_2)$ 进 transcript。
3. **两个 hard 判据** (任一触发即此 shot 在该因子上 hard):
 - (a) **不收敛**: 258 步后 终态 $u \neq 1$ ——截断把这个输入的 walk 带偏了、没归到 `gcd=1` (NonConvergence)。这一项自然地兜住了截断错误: 若某个被电路丢掉的位对这个输入其实非零, 截断 walk 就不会正确收敛。
 - (b) **transcript 离语言**: 把前 5 步决策打包成 `HEAD11` 的 15-bit pattern、后 3 步打包成 `TAIL3` pattern, 查它们是否在编解码器的可达语言内 (电路用压缩 sidecar 存这条决策日志, codec 只在可达 pattern 上可逆); 离语言 $\Rightarrow$ `HeadK5Mismatch` / `Tail3Top32Mismatch`——电路的压缩日志会非可逆。
4. 该 shot **clean** 当且仅当 dx 与 c 都不 hard; 整个 nonce GCD-clean 当且仅当全部 9024 shot 都 clean。

为什么便宜: 每 shot 只是 258 步 $\times$ 每步几个 256-bit 整数运算 (比较/减/移位/打包), 没有 1168-qubit 态、没有 10.3M-op 演化——故达 $\approx 8.6\text{k}-23.5\text{k}$ nonce/s (约 op-loop 的 **100**×), 在 classical-GCD 轴上**拒掉** $\approx 99.9\%$, 只把 GCD-clean 的 $\approx 0.09\%$ 交给 Stage-2。保守 (0 false-hard: 它走的就是

硬件的截断决策，绝不拒掉真赢家），但不精确：它只重放 GCD 求逆段、**不重放 apply 阶段**，所以放过的 GCD-clean 里只 $\approx 20\%$ 在精确 op-loop 下真正经典干净，其余 $\approx 80\%$ 是 apply 阶段截断的 false-clean（见后文“微妙翻转”段）。

6.3 两阶段 GPU 流水线 (Lever B)

把以上两半合起来——便宜的解析预过滤 (§6.2) 作 Stage-1、GPU validator (§6.1) 作 Stage-2——就是两阶段流水线（见图 3）：

- **Stage 1**——gpu-nonce/gcd.cu 解析预过滤：拒掉 $\approx 99.9\%$ ，不跑 op-loop。
- **Stage 2**——verify_dual/hunt_phase.cu 精确 GPU op-loop，只对 Stage-1 幸存者运行，逐 batch 在第一个经典或相位失败处早退，产出 DUAL_CLEAN_CANDIDATE。
- **复核**——唯一的赢家在提交前由官方 CPU eval_circuit 重新认证。

三个别混淆的速率。图 3 与表 2 里的 ≈ 169 nonce/s/卡 (8 卡 $\approx 1,355$) 是 op-loop 验证器跑在【原始 nonce 流】上的速率——即单阶段（对每个 nonce 都跑 op-loop、大多数在 classical 早退）的瓶颈数，也是把 validator 搬上 GPU 相对 CPU fleet ($\approx 40/s$) 的 $34\times$ 之处。它不是两阶段里 Stage-2 的吞吐：

- 管线扫【原始 nonce】的速率由 Stage-1 主导： $\approx 8.6k-23.5k$ /卡 (8 卡 $\approx 7-19$ 万/s) ——这才是“扫了多少 nonce”。
- **Stage-2 处理【候选】的速率**： ≈ 2.7 /卡 (8 卡 ≈ 22 候选/s；实测 900 候选 ≈ 335 s)。注意它比 169/卡慢——GCD-clean 候选是 cls-clean 的，在 op-loop 里跑得更深（到相位失败 $\approx$ batch 8、或更晚的经典才早退），而随机 nonce 大多在经典极早退；但 Stage-2 只需处理 $\approx 0.09\%$ 的幸存者，故毫不吃力。

一句话：1,355 是单阶段验证器在原始流上的速率（两阶段正是要绕开它）；两阶段实际扫 nonce 的速率是 Stage-1 的、约 $100\times$ 于它。

6.4 工具对齐门：信任任何 GPU verdict 的前提

GPU 工具按 path 链接 quantum_ecc，因此它们在设备上跑的是电路的自有一份拷贝。其判决要有效，这份拷贝必须与官方 build_circuit 的电路逐 op 一致：既然测试岛是 SHAKE256(op-stream)，op-stream 哪怕差一个 op，每个 nonce 的岛都不同，于是**每一个经典/相位判决都失效**（在失准工具上 hunt，即便扫到赢家也无法确认）。两种常见的分叉来源——都靠下面的对齐门拦截：(a) **陈旧编译的依赖**：Cargo 增量编译可能在源码已变后仍链接旧的 build()（二进制 mtime 看着新、依赖却没重编）——规则是改 src 后 cargo clean + 重建（日志须出现 Compiling quantum_ecc）；(b) **旋钮未校准**（见 §6.5）。

对齐门(强制前置检查)。信任任何 GPU 判决之前，先确认一个已知干净的 baked nonce 被工具读成双重干净。因 NONCE_BITS = 48，测其低 48 位(如 $2150000021998006 \bmod 2^{48} = 179675185023414$)。

这是 per-channel-zero 思想的对齐版：一个定义上 0/0/0 的 nonce 必须被工具确认 0/0/0，否则工具与官方电路不对齐——**停下重对齐，不要 hunt**。（注意：circuit_prep 的 n_ops 与 build_circuit 的 total_ops 之差不是可靠判据——前者是 slot 压缩计数；以对齐门为准。）

6.5 对改比较器的候选做 filter 校准

凡是改了预过滤所建模的比较器的候选（例如 DIALOG_GCD_COMPARE_BITS 46→45），必须同时重建 GPU dump (circuit_prep) 和 Stage-1 filter，并校准到新旋钮（把该旋钮 export 给 circuit_prep、gpu-nonce、verify_dual 三者）。用 cb-46 校准的 filter 去扫 cb-45 的电路，会得到一批校验后卡在很高经典地板上的候选——这是一个伪装成“死候选”的假结构地板。

6.6 投 fleet 前的筛选与判定（约 10 分钟预检）

把以上各零件拼成一条**投多小时 fleet hunt 之前的预检流程**，回答“这个候选值不值得、能不能 hunt”。这套筛选思路借自 ecdsafail_skills (§7)，现已是本仓库 hunt 的标准前置——它正是把对齐门、filter 校准、通道诊断、运行时模型这些零件按顺序串起来用：

1. **分数筛（值不值）**：build 候选 + eval_circuit（任意 nonce 即可，失败也会报 avg-T 与 q ）⇒ 确认 $\text{avg_T} \times \text{peak} < \text{前沿}$ 。
2. **对齐门（工具可不可信）**：§6.4——已知干净 baked nonce 必须读成 dual-clean，否则停下重对齐。
3. **建校准的 dump + filter**：§6.5——把候选旋钮 export 给 circuit_prep / gpu-nonce / verify_dual。
4. **小批扫描**：扫 ~12M nonce（几分钟）⇒ 收 ~900 个 GCD-clean 幸存者。
5. **verify_dual 这 ~900 个**（单卡 ~5 min）⇒ 得通道分布 dual / cls / pha。
6. **读判定**：用下面的逐通道诊断（本节余下）+ §6.7 的 ETA ⇒ **GREEN（投 fleet） / RED（弃）**，并报 $p50/p90/p99$ 。

要点：老办法跳过这 6 步、直接盲投 fleet，出不了赢家时分不清是工具坏 / 结构死 / 只是深；这套预检在烧几小时算力前就把三者分开。下面先展开第 6 步的判定诊断，再给 ETA 模型，最后是一个完整实例。

第 6 步：逐通道诊断——“我该不该继续 hunt？”

判定就是让上一步的 ~900 个 Stage-1 幸存者（已通过对齐过的 verify_dual）的通道结构来回答：

- **leak $q = P(\text{pha}=0 \mid \text{cls}=0)$** ——经典干净里同时相位干净的比例。在 1caf521 实测：leak ≈ 1 （ ≈ 180 个 cls-clean 中 0 个 pha-clean）。相位是一条独立的绑定通道；GCD 预过滤完全不富集它。因此 hunt 是相位-eval 受限的——光加 Stage-1 GPU 没用。
- **结构地板 vs. 深尾**——把候选的画像（cls-clean 比例、leak、failbatch 谱）与一个已知可 hunt 的基线（即 live frontier 本身）对比。若一致，候选就是深统计尾（可 hunt，只是稀有），而

非死路。严格版是失败-shot 重叠测试：导出若干低-clb 候选的失败-shot 下标——若总是同一批 shot 复现 $\Rightarrow$ 结构地板（放弃）；不同 shot $\Rightarrow$ 统计尾（继续 hunt）。

- 注意 900 个候选里 0 个双重干净不等于“没有赢家”：可用的 frontier 自己在该分辨率下也是 0/900；它的赢家是在数百万个 nonce 上扫出来的。这正是深尾的特征。

6.7 标定的运行时模型

把“到岛时间”建模为带经验修正的两阶段漏斗：

$$\text{island_rate} = d \cdot P(c=0) \cdot P(p=0 \mid c=0) \cdot P(a=0 \mid c=0, p=0), \quad E[N] \approx k \cdot \frac{1}{\text{island_rate}},$$

其中 $d = e^{-\lambda_{\text{GCD}}}$ 是 Stage-1 通过密度（由全-nonce 的 GCD-hard 均值估计，而非由稀有的零估计），通道零率用 Poisson 或负二项（针对过离散的、被筛过的子总体）， $k = \text{median}(\text{actual}/\text{predicted})$ 从每次落地的 hunt 中学得。等待是指数分布的，故 $p_{99} \approx 4.6 \times$ 均值——永远报告 $p_{50}/p_{90}/p_{99}$ ，绝不只报均值。

6.8 Worked example: 候选 cb45 (COMPARE_BITS 46 $\rightarrow$ 45)

新方法被用在一个旧方法曾 hunt 失败的候选上：

- **分数**：相对 cb-46 基线 -201,076（更小的比较器，在 $q=1168$ 不变下 -172 平均 Toffoli）——分数为负，值得 hunt。
- **可 hunt 性**：用修好且校准过的工具，cb-45 的通道画像（179 cls-clean/900, leak ≈ 1 ，最大 failbatch 43/141）与可 hunt 的 cb-46 前沿（180/900，最大 failbatch 48）在统计上一模一样 $\Rightarrow$ **cb-45 是深尾，而非死路**。旧的失败归因于陈旧工具和/或一个校准错位的 filter——两者在此都已修复。

6.9 把整条搜索加速的杠杆（按收益排序）

表 4 列出可加速整条搜索的杠杆。要点是把那条根本性的墙（ $P(\text{dual-clean})$ 很小，是线性加速治不好的）与那些确实把墙钟时间砍下来的工程杠杆区分开。

一个关于预过滤的微妙翻转（值得记录）。 在 84d5b0e 上，CPU filter 模型曾经过严（把硬度高估约 3.3 $\times$ ，几乎不给任何富集）。到 1caf521，情况翻转了：gcd.cu 现已有正确的 HEAD11 编解码器（与 CPU 支持表逐字节一致，且 dx/c 两个因子都查），它不再过严——反而欠拒绝： ~ 900 个 GCD-clean 候选里只有 $\approx 20\%$ 在 op-loop 下真正经典干净（其余 $\approx 80\%$ 是 false-clean）。原因是 gcd.cu 只建模 GCD 求逆段的硬输入，不管完整 point-add——一个 nonce 可以 GCD-clean 却经典脏，坏在 APPLY 阶段的截断或下游算术，而这些 GCD replay 并不建模。让它精确 = 把 apply 阶段也解析建模（工作量大、收益有限，因为真正的墙是深相位尾 / leak ≈ 1 ）。它仍然安全（无 false-HARD：绝不拒掉真赢家），所以照现状仍是个有效的富集预过滤器。

杠杆	收益	工作量	状态
修正经典预过滤的过严/欠拒（让其硬输入模型匹配真实电路，且保持 0 假干净），把昂贵 op-loop 只留给幸存者	~ 5-10× 系统吞吐	高	开放——真正的杠杆
多 GPU 独立进程 （每卡一个 <code>verify_dual</code> ，不相交范围，绕开损坏的 8-卡同步）	最高 8×	低	已完成模式
减小 <code>verify_dual</code> 每线程状态（gather buffer / tile state），提升 occupancy	1.5-3× 单卡	中	开放
加机器 ——把 zan5(8×RTX-5090)同步到同一前沿，照样跑独立进程 fleet	+8 卡（≈ 2×）	低	开放
分级 shot ——先用子集（512→2048）做相位校验，幸存者再升到全 9024	常数因子	中	部分（已有逐 batch 早退）
廉价-RNG 相位预过滤 ——相位 garbage 对任意 RNG 都会触发，故用快速 xorshift 替代 SHAKE 做一遍预过滤，幸存者再交 CPU 复核	削减 keccak 负载	中	开放

表 4: 加速整条搜索的杠杆。**根本极限（非 bug）**: $P(\text{dual-clean})$ 很小，无论扫得多快，一个新赢家都需要 $\sim 10^7\text{--}10^8$ 个 nonce。以上加速都是线性的——它们按比例缩短墙钟（例如 8 卡在“修好预过滤”后的速率下，可把一次 ~ 20 小时的 hunt 缩到 $\sim 1\text{--}2$ 小时），却无法让稀有岛候选“立刻”。挑选亚悬崖 / 值精确的候选（更少的新增硬输入 $\rightarrow$ 更高的 P ）才能让 hunt 变短。

7 从两个同行仓库借鉴的思路

研究了两个同行仓库:`ecdsafail_skills`(一个 7-skill 的 agent 库)与 `ecdsafail_gpu_toolkit` (一个 GPU 岛-hunting 工具箱)。表 5 汇总了采纳了什么、各解决了什么。

7.1 来自 `ecdsafail_skills`

- **逐通道-零 go/no-go** (`cls/pha/anc` 三通道分解): 每条通道都必须独立地在某处达到 0，否则 0/0/0 在结构上不可达。解决: 对死路的廉价提前枪毙，以及揭示出“相位是这里的绑定通道”这一框架。
- **失败-shot 重叠测试**: 区分结构地板（每个 nonce 都同一批 shot 失败）与深统计尾（不同 shot）。解决: 盲 hunt 永远回答不了的“继续 hunt 还是放弃”——这正是我们能宣告 cb-45 可 hunt 而非死路的依据。
- **标定的两阶段运行时模型**（条件漏斗; Poisson/NB 离散; 常数 k ; $p_{50}/p_{90}/p_{99}$ ）。解决: 诚实的 ETA 以及对候选的相对排序，取代了只看密度的乐观估计。

- **双因子预过滤**：一个 shot 只要任一 GCD 因子 (dx 或 c) 硬就算硬；只查 dx 会把硬率低估 $\approx 2\times$ 、产出假干净岛。解决：确认 Stage-1 预过滤确已检查两个因子——一条必须保持的正确性不变式。
- **已归档的死路与前沿考古**：jumpdivsteps NO-GO、WIDTH_SLOPE 密度悬崖 ($\sim 25\times/\text{notch}$)、批量对偶求逆的亏损、ops.bin 缓存陷阱、ZX/T-par 零抵消；外加前沿阶梯与双钉峰情报。解决：阻止我们重走已证死路，并标定下一个真正的赢点在哪。

7.2 来自 ecdsafail_gpu_toolkit

- **两阶段 scan $\rightarrow$ validate 纪律与密度门控** (candidates/M-nonce 阈值)。解决：在投入 GPU 小时之前有原则的 stop/go。
- **惰性求值“apply 预扫”** (EVAL_FAST_REJECT)：与其在 GPU 上重新实现 apply 阶段，不如让受信任的 CPU eval_circuit 快速失败。对照：我们的工具箱下了相反的赌注——它把相位 op-loop 放在 GPU 上跑 (hunt_phase kernel) 以产出真正双重干净的候选——但惰性求值这个想法作为更便宜的回退仍值得保留。
- **把旋钮当作精确加速的卫生学**：批量模逆 (GPU_BATCH_INV)、运行时定基 comb 表 (GPU_COMB_BITS)、安全的 GCD 重排 (trunc_first)、nonce-fan SHAKE 缓存——每个都是带正确性冒烟测试的精确开关。解决：一套在不冒假阴性风险下添加加速的模板。

借鉴的思路	来源	在这里解决了什么
逐通道-零 go/no-go	skills	廉价枪毙死路；发现相位是绑定通道
失败-shot 重叠测试	skills	结构地板 vs 深尾的判定 (cb-45 被判为可 hunt)
标定运行时模型	skills	诚实 ETA + 候选排序；尾部分位数
双因子预过滤	skills	确认并锁定 $dx \vee c$ 硬输入不变式
死路 + 考古	skills	避免重走已证死路；前沿情报
两阶段 + 密度门控	toolkit	投 GPU 小时前的有原则 go/no-go
惰性求值快速拒绝	toolkit	比 GPU 相位 op-loop 更便宜的 CPU 侧回退
精确旋钮加速卫生学	toolkit	安全添加 GPU 加速的模板

表 5: 从两个同行仓库采纳的思路，以及各自解决的问题。

7.3 本仓库相对 ecdsafail_gpu_toolkit 的关键领先

借鉴并非单向——本仓库在 GPU 工具上有两处竞品工具箱没有的能力：

- **GPU validator**：§6.1 所述“把完整 classical+phase op-loop 搬上 GPU”正是关键差异——竞品 ecdsafail_gpu_toolkit 只把 Stage-1 (GCD 预过滤) 放 GPU，把 Stage-2 的昂贵 validate 留在 CPU (用 EVAL_FAST_REJECT 让 CPU eval_circuit 快速失败，刻意不在 GPU 重写 apply/phase)。即本流水线**两阶段都在 GPU**，竞品只有 Stage-1 在 GPU ——这正是相位通道能被流式校验、不必回落 CPU fleet 的原因。

- 更快的经典预过滤内核 ($\approx 2\times$): 本仓库 `gcd.cu` 达 $\approx 23.5\text{k nonce/s}$ (HC=8 批量模逆 + 16-bit comb 表 + `launch_bounds` 调优), 约为竞品 ($\approx 10\text{--}12\text{k}$) 两倍。

取舍: GPU 相位 `op-loop` 很重 ($\approx 169\text{ nonce/s}$) ——这正是两阶段 (便宜预过滤 → 仅对幸存者跑 `op-loop`) 必要性的来源; 竞品的“惰性 CPU 求值”是一个值得保留的、更便宜的 Stage-2 回退。

8 新工作流为何更好（之前 → 现在）

表 6 把本轮修复前后的工作流并排对比, 凸显从“盲 hunt 碰运气”到“先筛选、判定、再投 fleet”的转变。

	之前（静默失败）	现在（本轮）
陈旧工具	hunt 跑在分叉电路上, 判决全是垃圾; 扫到赢家也确认不了	对齐门 (baked nonce → 双重干净) 在 hunt 前就抓出来
改比较器旋钮	用错位 filter 扫 → 假结构地板	重建 dump + filter, 校准到该旋钮
“出不了赢家”	分不清结构死路 / 深尾 / 工具坏了 → 放弃了可 hunt 的候选或死磕死路	通道筛选 (leak + 对比 frontier 画像 + 重叠测试) 在投 fleet 前给出判定
决策方式	盲 hunt, 碰运气	筛选 → 判定 → 才投 fleet hunt; 赢家用 CPU <code>eval_circuit</code> 复核

表 6: 修复前后的工作流对比。

9 当前状态与开放项

- 工具链**: 已修复 (陈旧构建缺陷), 并已对齐门校验。
- 活跃 hunt**: `cb45` (-201k 分) 正在 `zan3` 的 8 卡上、用修复且 `cb-45`- 校准的两阶段流水线 hunt; 赢家提交前 CPU 复核。
- 已知限制**: Stage-1 预过滤只建模 GCD 求逆、不管 `apply` 阶段, 所以它的“GCD-clean”候选里约 80% 在 `op-loop` 下是经典脏。让它精确 = 解析地建模 `apply` 阶段 (工作量大、收益有界, 因为绑定墙是深相位尾 / $\text{leak} \approx 1$)。
- 最高杠杆的开放杠杆**: 一次能塌缩 *leak* 的电路侧改动 (让测量-uncompute 相位只在经典截断也失败的地方失败) ——这会让便宜的经典预过滤同时富集两条通道。